

1. Descripción del Proyecto

Exposición del problema o necesidad al cual el trabajo de titulación dará un aporte. Responde a preguntas como: ¿cuál es el problema?, ¿por qué es importante?, ¿qué se conoce al respecto hasta ahora?, ¿qué hipótesis se plantea?, ¿cómo lo va a hacer?, y ¿cuáles son los resultados esperados?. Citar datos específicos con las referencias relevantes correspondientes. Exponer de forma concreta aspectos referentes a la metodología, actividades principales, y recursos a emplearse. Referirse a materiales y métodos incluyendo una descripción del diseño de investigación, recolección de datos, y de los métodos para procesamiento y el análisis de los datos. Espacio limitado a dos páginas (800 palabras).

Imagina un mundo donde las empresas, sin importar su tamaño, pueden atender a sus clientes 24/7, brindando respuestas instantáneas a cualquier pregunta. Esto es justamente lo que muchas compañías buscan hoy: aumentar su alcance y estar disponibles cuando el cliente lo necesita [10]. Para lograrlo, una de las alternativas ha sido implementar chatbots que les permitan interactuar en tiempo real, respondiendo consultas y promoviendo productos o servicios [2].

Sin embargo, estos chatbots presentan una limitación crítica: dependen de palabras clave, lenguajes de consulta formales o menús predefinidos [12]. Según su definición, un chatbot es "un programa de computadora diseñado para simular una conversación con usuarios humanos" [5]. Pero esta interacción, en la práctica, no es natural ni dinámica. Esto va en contra de lo que revelan los estudios realizados en [4], donde se ha demostrado que los usuarios prefieren interfaces en las que puedan comunicarse en lenguaje natural, sin tener que ajustarse a estructuras rígidas o a un lenguaje técnico [4]. En otras palabras, quieren hacer preguntas como si estuvieran hablando con otra persona, no con una máquina.

En entornos empresariales o institucionales, una de las principales limitaciones es que el acceso a la información de la organización suele estar restringido a personas con conocimientos técnicos, lo que ralentiza la ejecución de procesos y la toma de decisiones [15]. Para superar esta barrera, los Large Language Models (LLMs) ofrecen una solución prometedora, ya que permiten una interacción en lenguaje natural accesible para todos, facilitando conversaciones de alta calidad [7]. No obstante, persiste el reto de integrar estos modelos con los datos específicos de cada organización para interactuar con la información interna y generar respuestas contextualizadas [6].

Una solución actual son los sistemas text2SQL que traducen consultas en lenguaje natural a SQL [15], pero su principal limitación es la falta de interactividad dinámica y la incapacidad de mantener diálogos fluidos con contexto [8]. Para superar esta restricción, la tecnología RAG (Retrieval-Augmented Generation) amplía el contexto mediante la recuperación de información relevante, lo que mejora tanto la calidad de los datos como la relevancia de las respuestas, al mismo tiempo que incorpora contexto adicional y reduce sesgos o alucinaciones [3][8].

Evaluar el desempeño de RAG implica analizar cómo recupera y contextualiza información relevante, asegurando precisión y fluidez. Entre los aspectos clave están la fidelidad, que verifica que las respuestas respeten la exactitud de los datos; la relevancia, que determina la adecuación de la información recuperada; la precisión del contexto, que valida la correcta clasificación de elementos, y la similitud semántica, que asegura que la respuesta sea comprensible y clara para el usuario [8].

Para resolver los problemas de falta de fluidez en la interacción, la escasa adaptación a los datos específicos de una organización y la limitada democratización de la información, se propone el desarrollo de un chatbot multiagente basado en modelos LLM y una arquitectura RAG, capaz de interactuar de manera dinámica con los datos de una empresa. La arquitectura multiagente permitirá gestionar diferentes aspectos de la interacción, asignando tareas a agentes específicos como entender el contexto de las consultas, recuperar información relevante y generar respuestas de manera coherente, permitiendo una experiencia de usuario mucho más natural y flexible que los chatbots tradicionales.

El flujo de trabajo comenzará con la extracción de datos proporcionados por una institución de educación superior, que incluye 30 tablas y 20,000 registros con información de empleados, estudiantes y datos administrativos. Posteriormente, se llevará a cabo un preprocesamiento de los datos con el fin de transformar los registros en documentos de texto los cuales se dividirán en fragmentos de textos (chunks). Estos fragmentos se convertirán en embeddings y se almacenarán en una base de datos vectorial como Chroma. Cuando un usuario realice una consulta en lenguaje natural, este contexto será utilizado por el modelo de lenguaje Llama 3.1, que ofrece una calidad comparable a los principales modelos de lenguaje, como GPT-4, para generar respuestas precisas y coherentes [1]. La interacción se gestionará mediante una arquitectura de agentes, orquestada por CrewAI, lo que permitirá gestionar múltiples agentes de IA que colaborarán en el procesamiento de las consultas de los usuarios. Para la gestión de este flujo de trabajo, se emplearán herramientas como Airflow y Python, y se utilizará LLMOps, un conjunto de prácticas y herramientas diseñadas para agilizar la gestión del ciclo de vida de los LLM [9].

La evaluación de los resultados se llevará a cabo mediante dos métricas principales. La primera será la formulación de preguntas puntuales, cuya respuesta ya se conoce, lo que permitirá verificar la precisión de las respuestas generadas por el chatbot y detectar posibles alucinaciones, es decir, respuestas incorrectas que el modelo genera sin fundamento en los datos originales [3]. La segunda métrica será el feedback de los usuarios (*Reinforcement Learning from Human Feedback*, RLHF), donde se evaluará la satisfacción en cuanto a la fidelidad, relevancia, precisión del contexto y la claridad de las respuestas proporcionadas.

2. Objetivos

Objetivo General: Identifica la finalidad hacia la cual irá dirigido el trabajo. La redacción responde a las preguntas ¿qué? y ¿para qué?.

Objetivo(s) específico(s): Cuyo cumplimiento aporta al logro del Objetivo General (máximo cuatro). Exponerlos de manera clara y coherente con el tema propuesto; deben ser medibles en términos de logros o impactos observables. Deben estar vinculados con las diversas actividades a desarrollarse.

Objetivo General

Desarrollar un chatbot multiagente basado en LLM (Large Language Model) y arquitectura RAG (Retrieval-Augmented Generation) que interactúe con la base de datos de una institución de educación superior, con el fin de democratizar el acceso a la información para que cualquier persona pueda realizar consultas a una base de datos mediante lenguaje natural.

Objetivos específicos

1. Implementar un chatbot multiagente adaptable que permita su implementación en múltiples dominios, facilitando la reutilización en diferentes contextos empresariales e institucionales.
2. Determinar la efectividad de la arquitectura RAG en la integración de contexto relevante con un LLM, evaluando su capacidad para mejorar la fidelidad, la relevancia, la precisión del contexto y la semántica de las respuestas generadas en consultas basadas en lenguaje natural.
3. Evaluar la eficiencia del uso de agentes de IA en comparación con pipelines tradicionales en entornos empresariales, midiendo su impacto en la gestión y procesamiento de consultas complejas.
4. Realizar pruebas con diversos formatos de datos para crear embeddings y experimentar con múltiples modelos LLM, identificando la combinación de modelos y técnicas que proporcione los mejores resultados en cuanto a fidelidad, relevancia, precisión del contexto y la semántica en las respuestas.

3. Alcance o Contenido Propuesto

Indicar los Capítulos y los principales subcomponentes que conformarán el desarrollo del Tema propuesto. La estructura básica deberá plantearse en términos de: Introducción, Materiales y Métodos, Resultados y Discusión, Conclusiones, Referencias

1. Introducción
 - 1.1. Motivación
 - 1.2. Descripción del problema

- 1.3. Alcance del trabajo
- 1.4. Objetivos del trabajo
 - 1.4.1. Objetivo general
 - 1.4.2. Objetivos específicos
- 1.5. Metodología
- 1.6. Estructura del documento
2. Antecedentes y trabajos relacionados
 - 2.1. Chatbots
 - 2.2. Large Language Models
 - 2.3. Text2SQL
 - 2.4. RAG
 - 2.5. AI Agents (RAG Agents)
3. Metodología del desarrollo
 - 3.1. Herramientas usadas
 - 3.2. Recopilación y preparación de datos
 - 3.3. Creación de una plantilla para los datos
 - 3.4. Construcción de los embeddings
 - 3.5. Definición de RAG y Agentes de AI
 - 3.6. Validación y evaluación del modelo
4. Adaptación de LLM y formato de Datos
 - 4.1. Generación de embeddings con diferentes representaciones de los datos
 - 4.2. Prueba de modelo Vanilla RAG usando diferentes LLMs
 - 4.3. Prueba de modelo Agentic RAG usando diferentes LLMs
5. Resultados
 - 5.1. Resultados
 - 5.2. Discusión
6. Conclusiones
 - 6.1. Conclusión
 - 6.2. Contribución
 - 6.3. Trabajo Futuro
7. Referencias
8. Apéndices
9. Anexos
10. Glosario de términos

4. Bibliografía identificada y otras referencias (Ver Anexo para citar referencias)

- [1] A. Dubey et al., «The Llama 3 Herd of Models», 15 de agosto de 2024, arXiv: arXiv:2407.21783. Accedido: 22 de octubre de 2024. [En línea]. Disponible en: <http://arxiv.org/abs/2407.21783>
- [2] Adam, M., Wessel, M., & Benlian, A. (2020). AI-based chatbots in customer service and their effects on user compliance. *Electronic Markets*, 31(2), 427-445. <https://doi.org/10.1007/s12525-020-00414-7>
- [3] Bhavsar, P. (2024). Mastering RAG: A comprehensive guide for building enterprise-grade RAG systems.
- [4] Chai, J., Horvath, V., Nicolov, N., Stys, M., Kambhatla, N., Zadrozny, W., & Melville, P. (2002). Natural language assistant: a dialog system for online product recommendation. *AI Magazine*, 23(2), 63.
- [5] chatbot | Definition of chatbot in English by Lexico Dictionaries. <https://www.lexico.com/en/definition/chatbot>

- [6] Crimi, Alessandro .(2023, octubre 5). All you need to know about your app using LLM and RAG. Medium. <https://medium.com/gitconnected/all-you-need-to-know-about-your-app-using-llm-and-rag-e1eb0874546f>
- [7] Eisman, E. M., Navarro, M., & Castro, J. L. (2016). A multi-agent conversational system with heterogeneous data sources access. *Expert Systems with Applications*, 53, 172-191. <https://doi.org/10.1016/j.eswa.2016.01.033>
- [8] Huang, J. (2024, 28 marzo). Evaluating Large Language Model (LLM) systems: Metrics, challenges, and best practices. Medium. <https://medium.com/data-science-at-microsoft/evaluating-llm-systems-metrics-challenges-and-best-practices-664ac25be7e5>
- [9] J. Diaz-De-Arcaya, J. López-De-Armentia, R. Miñón, I. L. Ojanguren, y A. I. Torre-Bastida, «Large Language Model Operations (LLMOps): Definition, Challenges, and Lifecycle Management», en 2024 9th International Conference on Smart and Sustainable Technologies (SpliTech), Bol and Split, Croatia: IEEE, jun. 2024, pp. 1-4. doi: 10.23919/SpliTech61897.2024.10612341.
- [10] Kushwaha, A. K., & Kar, A. K. (2020). Language Model-Driven Chatbot for Business to Address Marketing and Selection of Products. En IFIP advances in information and communication technology (pp. 16-28). https://doi.org/10.1007/978-3-030-64849-7_3
- [11] Nandkumar, Chandran & Peternel, Luka. (2024). Enhancing Supermarket Robot Interaction: A Multi-Level LLM Conversational Interface for Handling Diverse Customer Intents. 10.48550/arXiv.2406.11047.
- [12] S. Mohamad Suhaili, N. Salim, y M. N. Jambli, «Service chatbots: A systematic review», *Expert Systems with Applications*, vol. 184, p. 115461, dic. 2021, doi: [10.1016/j.eswa.2021.115461](https://doi.org/10.1016/j.eswa.2021.115461).
- [13] Speier, C., & Morris, M. G. (2003). The Influence of Query Interface Design on Decision-Making Performance. *MIS Quarterly*, 27(3), 397–423. <https://doi.org/10.2307/30036539>
- [14] Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., & Wen, J. (2024b). A survey on large language model based autonomous agents. *Frontiers Of Computer Science*, 18(6). <https://doi.org/10.1007/s11704-024-40231-1>
- [15] X. Zhu, Q. Li, L. Cui, y Y. Liu, «Large Language Model Enhanced Text-to-SQL Generation: A Survey», 8 de octubre de 2024, arXiv: arXiv:2410.06011. Accedido: 27 de octubre de 2024. [En línea]. Disponible en: <http://arxiv.org/abs/2410.06011>

5. Plazo y Cronograma

Indicar plazo establecido, fecha proyectada para inicio de actividades y el cronograma de ejecución de actividades principales. (considerar que el trabajo de titulación está dimensionado para una duración de 400 horas)

Para la ejecución del estudio se plantea un plazo de de acuerdo al siguiente cronograma:

[illegible]

la tesis y los beneficios de integrar modelos LLM y RAG en un chatbot multiagente.																				
Planificar y diseñar la estructura general del sistema, incluyendo la integración de agentes, LLM, RAG, bases de datos y herramientas para orquestar el flujo de trabajo (Airflow, Python, Chroma).	Diseño de la arquitectura del sistema			x																
Obtener los datos necesarios de la institución educativa, procesarlos y transformarlos en un formato adecuado para su uso en el sistema.	Recolección y preparación de los datos				x	x	x													
Implementar y adaptar el modelo LLM	Implementación del modelo LLM, RAG y generación de embeddings							x	x	x										
Crear los agentes de IA especializados que interactuarán con el modelo LLM y RAG para procesar las consultas de los usuarios.	Desarrollo de la arquitectura de agentes de IA								x		x	x								
Desarrollar el chatbot en su forma inicial, integrando los modelos y agentes.	Desarrollo del chatbot y pruebas iniciales											x		x						
Evaluar la precisión de las respuestas del chatbot y realizar ajustes para evitar alucinaciones y mejorar la calidad de la interacción.	Evaluación de resultados preliminares y ajuste de la interacción												x	x						
Recoger retroalimentación de los usuarios y mejoras en el sistema	Feedback de usuarios (RLHF) y mejoras en el sistema														x	x				

[illegible]

Anexos:

Formato para referencias bibliográficas

Citar referencias en orden alfabético (Apellidos, Nombres), seguido del año de publicación, el título de la publicación, y la revista, volumen, editorial o información complementaria, así como páginas. Seguir la siguiente guía para información:

Tipo de publicación	Elementos específicos en la cita bibliográfica
Libros	Número total de páginas, Nombre de la casa editorial, Lugar (ciudad y país) de publicación
Publicaciones en revistas	Nombre de la revista, Volumen, Número, Número de páginas del artículo citado
Mapas	Escala, Nombre de la casa editorial o institución que lo publica, Lugar de publicación
Congresos, conferencias	Nombre del evento, Lugar en que se realizó, Serie o volumen (si existe), Número de páginas del artículo citad
Tesis e informes internos	Número total de páginas, Institución que respalda el trabajo. Preferiblemente se cita el nombre en el idioma en que se escribe el artículo, Lugar (ciudad y país) de publicación, Tipo de trabajo (de maestría, doctorado, reporte técnico etc.)
Recursos electrónicos en Internet	Institución y nombre de la revista, si existen explícitamente, Dirección electrónica del sitio y el detalle de donde aparece el artículo publicado, DOI (digital object identification) Si no existe una fecha explícita de publicación de la revista electrónica, se consigna la fecha de consulta del documento

Referencias: (Ejemplos)

Alvarado, G.E., Kussmaul, S., Chiesa, S., Gillot, P.-Y., Appel, H., Wörner, G. & Rundle, C., 1992. Resumen cronoestratigráfico de las rocas ígneas de Costa Rica, basado en dataciones radiométricas. *J. South Amer. Earth Sci.*, **6(3)**, 151-168.

De Boer, J.Z., Drumond, M.S., Bordelon, M.J., Defant, M.J., Bellon, H. & Maury, R.C., 1995: Cenozoic magmatic phases of the Costa Rican island arc (Cordillera de Talamanca). *Geol. Soc. Amer. Spec. Paper*, **295**, 35-55.

Dengo, G., 1962a: Tectonic-igneous sequence in Costa Rica. En: Engel, A.E.J., James, H.J. & Leonard, B.F. (eds.): A volume to honor A.F. Budington. *Geol. Soc. Amer. Spec.*, **131**, 133-161.

Dóndoli, C., 1968. Mapa geológico de Costa Rica. Escala 1:700 000, *IGN*, San José.

Dóndoli, C. & Chaves, R., 1968. Mapa adjunto al estudio geológico del Valle Central. Escala 1:150 000, *IGN*, San José.

Dóndoli, C. & Torres, A., 1954. Estudio geo-agronómico de la región oriental de la Meseta Central. *Min. Agricultura e Ind.*, San José, 180 págs.

Escalante, G, s.f.: El banquete del Irazú. <http://www.geologos.or.cr/historia.htm> [Consulta: 26 de diciembre del 2006].

Hauff, F., Hoernle, K., Boogardv.d., P., Alvarado, G.E., & Garbe-Schönberg, D., 2000. Age and geochemistry of basaltic complexes in western Costa Rica: Contributions to the geotectonic evolution of Central America. *Geochem. Geophys. Geosyst.*, **1(5)**, DOI: 10.1029/1999GC000020.

Kuijpers, E., 1979. La geología del Complejo ofiolítico de Nicoya. *Inf. Sem.*, *IGN*, **1979(2)**, 15-75.

Meschede, M., 1997. The abandoned spreading system of the Cocos and Malpelo ridges in eastern Pacific. [Resumen] *GSA Annual Meeting, Salt Lake City*, A-245.

Roberts, R.J., 1944. Manganese deposits in Costa Rica. *U.S. Geol. Surv.*, **935(1-4)**, 387-414.

Romanes, J., 1912. Geology of a part of Costa Rica. *Quarterly J. Geol. Soc. London*, **68**, 103-139.

Sprechmann, P. (ed.), 1984. Manual de Geología de Costa Rica. *Ed. UCR*, San José, 320 págs.

Weyl, R., 1980. Geology of Central America. [2a ed] *Gebrüder Borntraeger, Stuttgart*, 371 págs.

DiMarco, G., Baumgartner, P.O. & Channel, J.E.T., 1995. Late Cretaceous-early Tertiary paleomagnetic data and a revised tectonostratigraphy of Costa Rica and Panama. En: Mann, P. (ed.): Geologic and Tectonic development of the Caribbean plate boundary in southern Central America. *Geol. Soc. Amer. Spec. Paper*, **295**, 1-27.

Para abreviación de revistas consultar las siguientes páginas web:

http://www.efm.leeds.ac.uk/~mark/ISlabbr/A_abrvjt.html

<http://www.library.ubc.ca/scieng/coden.html#A>

http://home.ncifcrf.gov/research/bja/journams_a.html

Fecha (dd/mm/aa):	
Unidad de Titulación de la Carrera de Ingeniería de Sistemas	
Revisado por:	Ing. Andrés Auquilla S. Ing. Victor Saquicela G.
	Ing. Magali Mejía P. Ing. Oscar Alvear A.
Docente(s) recomendado(s) para Dirección / Tutoría del Trabajo de Titulación:	
Observaciones:	
Resultado de la revisión del Tema:	
Es procedente	•
No es procedente	•
Ing. Lorena Siguenza Guzmán, PhD Decana de la Facultad de Ingeniería Su Despacho.-	
Comunico que la Comisión Académica de la Carrera de Ciencias de la Computación ha revisado el presente proyecto de titulación y recomienda a usted que se sirva poner en conocimiento del Consejo Directivo de la Facultad, para la aprobación correspondiente.	
Atentamente,	
Ing. Jaime Veintimilla Reyes, PhD	
Director de la Carrera de Ingeniería en Ciencias de la Computación	

(Espacio reservado para conocimiento del Decano de la Facultad)

Pase para conocimiento y resolución del Consejo Directivo de la Facultad

Ing. Lorena Siguenza Guzmán, PhD

Fecha (dd/mm/aa):

DECANO DE LA FACULTAD DE INGENIERÍA

Solicitud adicional (Espacio reservado para el Consejo Directivo de la Facultad de Ingeniería para dar trámite a solicitud posterior)

Solicitud para:

Ampliación de plazo •

Anulación del Tema •

Resolución Acta N° _____

Se aprueba •

No se aprueba •

Observaciones: _____

Ing. Lorena Siguenza Guzmán, PhD

Fecha (dd/mm/aa)

DECANO (E) DE LA FACULTAD DE INGENIERÍA